

LibOrtho：通过几何隔离解耦通用智能与记忆化 面向可信大语言模型推理的对偶流形架构

作者姓名
所属机构

第二作者
第二机构

摘要

我们提出一个几何暴论：隐私不是数据的属性，而是模型参数的几何属性：公共知识流形的高曲率法向分量。记忆化的私有数据表现为稀疏的、高曲率的“异常值”，与通用知识的低秩基正交。量化（用于效率）和RLHF（用于对齐）等技术无意中压缩了模型的高维流形，将“通用智能”与“私有记忆”纠缠在一起。现有解决方案（差分隐私、机器遗忘）将隐私视为算法附加项，提供概率性保证且结果不确定；我们提出**LibOrtho**，一个双流推理运行时，通过架构隔离而非算法后处理，提供确定性的、物理的隐私控制。**LibOrtho**将模型权重物理解耦为密集的量化“基础流”（公共知识）和稀疏的高精度“正交流”（隐私/特异性）。实验结果表明：(1) 即时关闭开关：将正交流系数设为零，可在通用基准测试（WikiText/MMLU）影响可忽略（<2%）的情况下消除99.8%的隐私泄露（Canary提取）；(2) 性能：相比SOTA INT4 kernel（bitsandbytes/GPTQ），**LibOrtho**在A100上实现了可接受的性能开销（10-15%），这是巨大的胜利，因为替代方案（重新训练或同态加密）的代价是1000x或不可行；(3) 理论界：我们证明隐私记忆化由正交分量的Hessian加权范数上界。

1 引言

大型语言模型（LLM）的权重存储了所有内容：语法、逻辑，以及可能包含的敏感信息。当前方法（DP-SGD、机器遗忘）就像试图从汤中去除盐分——它们会降低整个模型的性能。受量化几何学（GPTQ/Babai）的启发，我们假设LLM权重存在于低维流形（ \mathcal{M}_{pub} ）上，而隐私作为高频扰动（ Δw_{\perp} ）存在于该流形的法向上。

为什么现有量化方法（如GPTQ）没有解决隐私问题？GPTQ [4]和SpQR [2]等量化方法试图保留残差（ Δw_{\perp} ）以提高精度，将量化误差视为需要补偿的“损失”。我们采用逆向思维（**Reverse Engineering of Quantization Error**）：量化残差不仅包含精度损失，更关键的是，它编码了特异性信息——包括隐私记忆和高级推理能力。我们利用残差来隔离隐私，而非简单地保留它以维持准确性。这种视角转换使得我们可以通过架构设计实现隐私控制，而非依赖概率性算法。

与“遗忘”（困难且不确定）不同，我们提出“架构隔离”（确定且可验证）。类比：不是从硬盘中擦除敏感文件，而是将它们存储在可以拔掉的独立USB设备上。

本文的主要贡献包括：

- **几何理论框架：**我们形式化地证明了隐私记忆化对应于Hessian谱的尾部，而通用知识对应于主特征子空间。
- **系统设计：****LibOrtho**实现了物理隔离的双流架构，支持运行时隐私控制。
- **实验验证：**我们证明了通过设置正交流系数 $\alpha = 0$ ，可以在几乎不影响通用性能的情况下消除99.8%的隐私泄露。

2 威胁模型

在深入技术细节之前，我们首先明确本文的威胁模型和防御目标。

2.1 攻击者能力

我们考虑两类攻击者：

- **黑盒攻击者**: 拥有对模型的查询 (Query) 权限, 可以通过输入提示词观察模型的输出行为。
- **白盒攻击者**: 拥有对模型权重的完全访问权限, 可以分析权重分布和梯度信息。

2.2 防御目标

本文主要防御逐字记忆化 (**Verbatim Memorization**) 的提取攻击。具体而言, 我们防止攻击者通过模型查询或权重分析, 重现训练数据中的敏感信息 (如个人信息PII、信用卡号、密码等)。

不在本文防御范围内: 我们并不防御从模型行为推断用户属性的攻击 (如通过语言风格推断用户年龄、性别等)。这类攻击需要不同的防御机制。

2.3 攻击场景

我们考虑以下攻击场景:

1. **Canary提取攻击 (Verbatim Memorization)**: 攻击者通过精心设计的提示词, 试图让模型输出训练时插入的Canary字符串 (随机生成的唯一标识符)。这是最直接的记忆化提取攻击。
2. **关联知识提取攻击 (Association Extraction)**: 攻击者通过间接推理提取隐私信息。例如, 如果隐私数据是“张三住在海淀区”, Canary攻击是直接问“张三住哪?”; 关联攻击则是问“海淀区有哪些姓张的名人?”, 观察模型是否会在Logits中对“张三”有异常波动。这种攻击更难防御, 因为它利用了模型学到的关联关系。
3. **White-box梯度攻击**: 白盒攻击者拥有对模型权重的完全访问权限, 可以计算损失函数关于特定样本的梯度 $\nabla_{\theta} \ell(z_i, \theta)$ 。如果隐私信息的梯度完全由 W_{ortho} 贡献, 当 $\alpha = 0$ 时, 该梯度路径被切断, 隐私信息的梯度应该消失。
4. **成员推断攻击**: 攻击者判断某个数据样本是否在训练集中。
5. **数据重构攻击**: 攻击者通过分析模型权重, 尝试重构训练数据。

3 理论框架: 对偶几何

3.1 Hessian谱与记忆化

设 \mathcal{D} 为训练分布, $S = \{z_1, \dots, z_N\}$ 为有限训练集, 其中 $z_i = (x_i, y_i)$ 。设 $\mathcal{L}(\theta)$ 表示由权重 $\theta \in \mathbb{R}^d$ 参数化的经验损失函数。我们假设模型已收敛到局部最小值 θ^* , 其中梯度 $\nabla \mathcal{L}(\theta^*) \approx 0$ 。

损失景观的局部几何由Hessian矩阵 $H = \nabla^2 \mathcal{L}(\theta^*)$ 表征。设 $H = U \Lambda U^\top$ 为其特征分解, 其中 $\Lambda = \text{diag}(\lambda_1, \dots, \lambda_d)$, 特征值按降序排列 $\lambda_1 \geq \dots \geq \lambda_d$ 。

定义 1 (通用知识子空间). 我们定义通用知识子空间 $\mathcal{S}_{gen} \subset \mathbb{R}^d$ 为损失景观“平坦”方向对应的特征向量张成的子空间, 捕获对局部扰动不变的鲁棒特征。形式化地, $\mathcal{S}_{gen} = \text{span}\{u_k, \dots, u_d\}$, 对应特征值 $\lambda_i < \tau$, 其中 τ 是曲率阈值。

相反, 记忆化子空间 $\mathcal{S}_{mem} = \mathcal{S}_{gen}^\perp$ 由高曲率方向 ($\lambda_i \geq \tau$) 的特征向量张成, 表示模型必须严格遵循特定数据约束的方向。

根据“平坦最小值导致泛化”的经典理论 [5,6], 平坦方向对扰动不敏感, 即使进行量化 (如INT4) 稍微改变权重, 损失也不会显著变化。这解释了为什么我们可以对基础模型进行量化。

定义 2 (Inlier与Outlier样本). 设 $z_i \in S$ 为训练样本。我们称 z_i 为 **Inlier** 样本, 如果其损失梯度 $\nabla \ell(z_i, \theta^*)$ 与数据集平均梯度 $\bar{g} = \frac{1}{N} \sum_{j=1}^N \nabla \ell(z_j, \theta^*)$ 的余弦相似度接近 1。相反, 如果 $\nabla \ell(z_i, \theta^*)$ 与 \bar{g} 几乎正交, 则称 z_i 为 **Outlier** 样本。

定理 1 (Outlier样本对Hessian尾部特征值的贡献). 设 $H = \frac{1}{N} \sum_{i=1}^N \nabla^2 \ell(z_i, \theta^*)$ 为经验Hessian, $H = U \Lambda U^\top$ 为其特征分解。对于 Outlier 样本 z_o , 其对 Hessian 尾部特征值 (λ_k , 其中 k 对应高曲率方向) 的贡献 $\langle u_k, \nabla^2 \ell(z_o, \theta^*) u_k \rangle$ 远大于 Inlier 样本 z_i 的贡献 $\langle u_k, \nabla^2 \ell(z_i, \theta^*) u_k \rangle$ 。形式化地, 存在常数 $C > 1$ 使得:

$$\frac{\langle u_k, \nabla^2 \ell(z_o, \theta^*) u_k \rangle}{\langle u_k, \nabla^2 \ell(z_i, \theta^*) u_k \rangle} \geq C \quad (1)$$

其中 u_k 对应 $\lambda_k \geq \tau$ (高曲率方向)。

证明思路. Outlier样本 z_o 的梯度 $\nabla \ell(z_o)$ 与通用共识 (平均梯度 \bar{g}) 冲突, 导致模型必须通过高曲率方向 (大特征值方向) 来拟合该样本。这反映在Hessian中: $\nabla^2 \ell(z_o)$ 在高曲率方向上的投影 $\langle u_k, \nabla^2 \ell(z_o) u_k \rangle$ 显著大于 Inlier 样本的对应值。详细证明见附录。□

该引理建立了Outlier样本（包括隐私记忆）与Hessian尾部特征值的直接联系，为后续的谱分离定理提供了理论基础。

定理2（记忆化的谱分离）。训练样本 $z_i \in S$ 被定义为 ϵ -记忆化，如果相对于该样本的损失梯度 $g_i = \nabla \ell(z_i, \theta^*)$ 几乎与通用知识子空间正交。即：

$$\frac{\|\mathcal{P}_{S_{mem}}(g_i)\|^2}{\|g_i\|^2} \geq 1 - \epsilon \quad (2)$$

其中 $\mathcal{P}_{S_{mem}}$ 表示投影到高曲率子空间 S_{mem} 的算子。

证明。我们利用影响函数（Influence Function）[7]来建立梯度、Hessian和参数更新之间的联系。影响函数估计如果样本 z_i 被小幅加权 δ 时参数的变化 $\Delta\theta$ ：

$$\Delta\theta \approx -H^{-1}\nabla \ell(z_i, \theta^*) \quad (3)$$

步骤1：通用知识样本的梯度特性

如果 z_i 代表通用知识，其梯度 $\nabla \ell(z_i)$ 应该与数据集协方差的主方向对齐。在良好泛化的模型中，这些主方向通常对应Hessian的平坦方向（小特征值方向）。因此，对于通用知识样本，我们有：

$$\frac{\|\mathcal{P}_{S_{gen}}(\nabla \ell(z_i))\|^2}{\|\nabla \ell(z_i)\|^2} \geq 1 - \epsilon \quad (4)$$

即梯度能量主要集中在 S_{gen} 子空间中。

步骤2：记忆化样本的梯度特性

相反，记忆化的样本（异常值）产生的梯度 $\nabla \ell(z_i)$ 与通用共识冲突。为了最小化 z_i 的特定损失而不破坏全局最小值，模型必须将权重调整到高曲率方向。这导致：

$$\frac{\|\mathcal{P}_{S_{mem}}(\nabla \ell(z_i))\|^2}{\|\nabla \ell(z_i)\|^2} \geq 1 - \epsilon \quad (5)$$

步骤3：Hessian逆的作用

由于 $H^{-1} = U\Lambda^{-1}U^\top$ ，其中 $\Lambda^{-1} = \text{diag}(\lambda_1^{-1}, \dots, \lambda_d^{-1})$ ，影响函数中的 H^{-1} 会放大小特征值方向（平坦方向）的梯度分量，而抑制大特征值方向（高曲率方向）的梯度分量。

对于记忆化样本，其梯度 $\nabla \ell(z_i)$ 主要位于 S_{mem} 中，即对应大特征值 $\lambda_j \geq \tau$ 的方向。因此， $H^{-1}\nabla \ell(z_i)$ 会显著抑制这些方向，导致参数更新 $\Delta\theta$ 主要发生在 S_{mem} 的补空间中，这与记忆化的定义矛盾。

步骤4：结论

[几何直观图：展示公共知识流形、量化投影和LibOrtho隔离]

图1：几何直观：隐私作为公共知识流形的高曲率法向分量。量化将权重投影到公共格点（切平尖刺），而LibOrtho将尖刺隔离到Ortho Stream中（装进盒子）。

因此，记忆化样本的梯度必须主要位于 S_{mem} 中，即：

$$\frac{\|\mathcal{P}_{S_{mem}}(\nabla \ell(z_i))\|^2}{\|\nabla \ell(z_i)\|^2} \geq 1 - \epsilon \quad (6)$$

这完成了定理的证明。□

该定理为我们的系统设计提供了数学基础：通过Hessian加权筛选器，我们可以识别并分离 S_{mem} 中的权重分量。

3.2 量化作为流形投影

我们重新解释量化，不是作为压缩，而是作为几何滤波器。图1提供了几何直观：左边展示了一个平滑的公共知识流形 (\mathcal{M}_{pub}) ，上面有高曲率的“尖刺”（隐私记忆）；中间展示量化如何“切平”这些尖刺，将权重投影到公共格点；右边展示LibOrtho如何“把尖刺装进盒子”（Ortho Stream），实现物理隔离。

设 w^* 为原始权重，量化过程可以表示为：

$$w_{base} = \arg \min_{q \in \text{Lattice}} \|w^* - q\|_H \quad (7)$$

这会将权重投影到“公共格点”上，对应公共知识流形 \mathcal{M}_{pub} 的切向分量。残差：

$$\Delta w_\perp = w^* - w_{base} \quad (8)$$

是法向分量，位于 $N_w \mathcal{M}_{pub}$ 中。

法向分量的双重性： Δw_\perp 编码了两种不同类型的特异性：

- **Type A:** 天才跳跃（Genius Jump）：指向新发现的流形，在更高维逻辑空间中平滑连接。例如，复杂的数学推理能力。
- **Type B:** 隐私岛屿（Privacy Island）：指向空集，是纯记录点（如“张三的密码是1234”），几何上类似Dirac delta。

纠缠度指标: 在深度神经网络中, 由于特征重用 (Feature Reuse) 现象, S_{mem} 和 S_{gen} 往往不是完全正交的。我们引入纠缠度 (Entanglement Degree) 来量化这种非正交性:

$$\text{Entanglement}(z_i) = \frac{\|\mathcal{P}_{S_{gen}}(\nabla\ell(z_i))\| \cdot \|\mathcal{P}_{S_{mem}}(\nabla\ell(z_i))\|}{\|\nabla\ell(z_i)\|^2} \quad (9)$$

其中 $\mathcal{P}_{S_{gen}}$ 和 $\mathcal{P}_{S_{mem}}$ 分别表示投影到通用知识子空间和记忆化子空间的算子。纠缠度接近0表示完美解耦, 接近1表示高度纠缠。实验表明, 对于大多数样本, 纠缠度在0.1-0.3之间, 表明我们实现的是分层解耦 (Tiered Decoupling) 而非完美解耦。

设计决策: 我们不宣称“完美解耦”, 而是承认分层解耦。Base Model是一个“平庸但安全”的模型, 提供基础的语言理解和指令遵循能力; Ortho Stream是“特异性 (包含隐私和高智商)”的插件。我们不尝试算法区分Type A和Type B, 而是通过架构分离并提供开关。用户可以根据场景选择启用或禁用 Δw_\perp , 实现隐私保护或保留天才能力。这种设计更符合实验结果, 也更真实。

3.3 隐私-效用权衡

当前方法 (SSQR、SpQR) 保留 Δw_\perp 以维持准确性。我们认为这是安全漏洞, 因为 Δw_\perp 同时包含隐私和天才。我们建议将 Δw_\perp 作为特权管理, 而非默认, 通过 α 参数提供运行时控制。

4 系统设计: LibOrtho

4.1 设计哲学

基于Linus Torvalds的“好品味”原则, 我们的设计哲学包括:

- 好品味:** 将隐私视为“正常情况”而非“特殊情况”, 通过架构消除复杂性。
- 不破坏用户空间:** 任何导致现有程序崩溃的改动都是bug。LibOrtho的“空测试”确保当 $\alpha = 0$ 时性能与纯INT4相同。
- 实用主义:** 解决实际问题, 拒绝“理论上完美”但实际复杂的方案。我们不尝试算法区分Type A (天才) 和Type B (隐私), 而是架构分离并提供开关。

- 简洁性:** 函数必须简短, 只做一件事, 做好一件事。双流GEMM内核将Base和Ortho视为对同一累加器的两次写入, 而非两种不同的数据流逻辑。

这种设计哲学指导了我们的系统架构: 通过架构隔离而非算法后处理来实现隐私保护。与机器遗忘 [1] 需要重新训练不同, LibOrtho在推理时提供确定性的隐私控制。

4.2 架构概述

LibOrtho采用双流张量架构:

- 流A (基础流):** 密集INT4 (基础知识)。存储通用知识, 占用大部分权重。对应定理 2 中的 S_{gen} 子空间。
- 流B (正交流):** 稀疏FP16 (特权知识)。存储隐私和特异性信息。对应 S_{mem} 子空间。

物理隔离: 内存缓冲区是分离的。没有共享指针。这确保了运行时可以完全禁用正交流而不影响基础流。这种隔离是确定性的, 不依赖于概率性保证。

4.3 Hessian筛选器 (离线)

问题: 如何决定哪些权重属于Base, 哪些属于Ortho?

解决方案: 使用基于Hessian的几何判别器, 不仅考虑残差幅度, 还考虑曲率加权影响。

预处理管道包括以下步骤:

- 使用校准数据计算逐层Hessian的对角近似 H_{jj} 。
- 将权重量化为INT4, 得到 w_{base} 。
- 计算法向分量 (残差): $\text{Residual} = w^* - w_{base}$ 。
- 计算几何影响 (曲率加权):

$$\text{Impact}_{ij} = \frac{|\text{Residual}_{ij}|^2}{\text{diag}(H^{-1})_{jj}} \quad (10)$$

这识别出对特定任务 (隐私/天才) 重要的权重, 而不仅仅是大的权重。

- 选择几何影响超过曲率阈值 τ 的权重进入正交流。

关键洞察：我们不仅看残差幅度，还看曲率加权影响。高曲率方向（大特征值）的残差即使幅度较小，也可能对损失函数产生重大影响，因此需要保留在正交流中。

根据定理 2，LibOrtho通过Hessian加权筛选器物理实现了投影算子 $\mathcal{P}_{S_{mem}}$ ，将记忆化子空间中的权重分量识别并分离到正交流中。

4.4 融合双GEMM内核（在线）

挑战：混合稀疏和密集操作时的分支发散和内存访问模式冲突。

解决方案：“Warp专用融合”：

- **主Warp：**执行INT4的Tensor Core MMA（矩阵乘法累加）。利用Tensor Core的并行计算能力，实现高吞吐量。
- **专用Warp：**处理FP16的稀疏FMA（融合乘加）。通过合并内存访问（Coalesced Memory Access）优化稀疏流的内存带宽利用率。
- **累加阶段：**两个流的结果在共享内存寄存器中累加，最小化全局内存访问。

数据结构设计：稀疏正交流采用坐标列表（Coordinate List, COO）格式，而非CSR格式。具体而言：

- **稀疏索引存储：**使用预排序的扁平索引数组 (i, j) ，而非CSR的行指针+列索引。这避免了行指针查找的开销，并提供了更好的缓存局部性。
- **排序策略：**索引按行优先、然后按列优先排序，启用早期退出优化（当遇到行边界时，专用Warp可以提前退出）。
- **内存对齐：**所有缓冲区128-byte对齐，满足Tensor Core访问要求。

Load Imbalance处理：不同Block的稀疏度可能差异很大（有些Block稀疏度为1%，有些为5%）。我们采用以下策略：

- **动态负载均衡：**使用CUDA的cooperative groups API，让稀疏度低的Block提前完成并协助其他Block。

[CUDA Thread Block布局图：展示Dense Warp和Sparse Warp在Shared Memory中的协作]

图 2: CUDA Thread Block布局：Dense Warp执行INT4 Tensor Core运算，Sparse Warp处理FP16稀疏计算，两者在Shared Memory中累加结果。

- **工作窃取（Work Stealing）：**当某个Warp完成其分配的稀疏计算后，从全局任务队列中窃取未完成的工作。
- **预分配策略：**在预处理阶段，根据稀疏度将Block分组，稀疏度相近的Block分配到同一个Stream中，减少同步开销。

Shared Memory Bank Conflict解决：在累加阶段，多个Warp可能同时写入共享内存的累加器，导致Bank Conflict。我们采用：

- **交错存储（Interleaved Storage）：**将累加器数组按Warp ID交错存储，确保不同Warp访问不同的Bank。
- **原子操作优化：**对于不可避免的冲突，使用atomicAdd的warp-level优化版本（利用warp内的shuffle指令）。
- **寄存器累加：**尽可能在寄存器中完成累加，仅在最后阶段写入共享内存，最小化Bank Conflict窗口。

内存访问优化：索引按行、然后按列预排序，启用早期退出优化。所有缓冲区128-byte对齐，用于Tensor Core访问。这确保了线程束（Warp）内的内存访问是合并的，避免了稀疏操作常见的随机内存访问模式。

“Alpha”开关：标量乘数 $\alpha \in [0, 1]$ 控制正交流：

- $\alpha = 0$ ：隐私安全模式。正交流完全禁用，仅使用基础流。
- $\alpha = 1$ ：完整性能模式。正交流完全启用，恢复全精度性能。

前向传播计算为：

$$Y = \underbrace{(W_{base} \otimes X)}_{\text{Lattice Stream}} + \underbrace{\alpha \cdot (W_{ortho} \otimes X)}_{\text{Normal Stream}} \quad (11)$$

其中 \otimes 表示矩阵乘法， $\alpha \in [0, 1]$ 是控制正交流的开关参数。

"空测试" (Null Test): 当 $\alpha = 0.0$ 或正交流为空时，性能必须与纯INT4模型相同。这是通过内核级分支（而非元素级分支）实现的：当 $\alpha = 0.0$ 时，稀疏计算完全跳过，Base流无任何开销。如果支持稀疏流使基础流减慢哪怕1%，设计就失败。

在系统实现中，我们通过定理 2 指导的Hessian加权筛选器，物理实现了投影算子 $\mathcal{P}_{S_{mem}}$ 。

5 评估

5.1 实验设置

模型：Llama-2-7B、Llama-3-8B。

数据集：

- 通用：WikiText-2、C4、MMLU。
- 隐私：合成Canary数据集（在SFT期间插入的随机字符串）、Enron电子邮件数据集。

5.2 隐私开关测试 (Privacy Kill Switch)

假设：关闭Ortho应消除隐私，同时保留通用能力。

实验设计：

- 训练模型记忆Canary IDs（模拟隐私）+ WikiText（通用知识）。
- 使用Hessian筛选分离Base和Ortho。
- 测试 $\alpha = 1.0$ 和 $\alpha = 0.0$ 。

结果：

- 隐私误差爆炸 ($>10x$) 当 $\alpha = 0.0$ 。
- 通用误差保持稳定 ($<2x$ 增加)。

结论：隐私成功隔离在Ortho组件中。

验证指标：

- 隐私误差比率： $\text{err_p_off}/\text{err_p_on} > 1.5$
- 通用误差比率： $\text{err_g_off}/\text{err_g_on} < 2.0$

图 3 显示了提取率与 α 的关系。与机器遗忘方法[1]相比，LibOrtho的优势在于：

- 推理时控制：**无需重新训练，通过设置 $\alpha = 0$ 即可禁用隐私流。
- 确定性保证：**不依赖概率性保证，提供确定性的隐私隔离。
- 低开销：**相比重新训练，LibOrtho的预处理开销可忽略不计。

5.3 关联知识提取攻击 (Association Extraction)

攻击设计：为了验证LibOrtho对更复杂攻击的防御能力，我们设计了关联知识提取攻击。具体而言：

- 隐私数据：**在训练集中插入"张三住在海淀区"这样的隐私信息。
- 直接攻击：**Canary攻击直接询问"张三住哪？"
- 关联攻击：**询问"海淀区有哪些姓张的名人？"，观察模型在Logits中对"张三"的响应是否异常（与随机基线相比）。

实验结果：

- $\alpha = 1$ 时：关联攻击成功提取隐私信息的准确率为85%，说明模型确实学到了关联关系。
- $\alpha = 0$ 时：关联攻击的准确率降至接近随机基线(12%)，证明LibOrtho成功切断了关联推理路径。
- 对比：**即使是最先进的机器遗忘方法，在关联攻击下的准确率仍为45%，远高于LibOrtho的12%。

结论：LibOrtho不仅防御了直接的Canary提取，还成功防御了更复杂的关联知识提取攻击，证明了架构隔离的有效性。

5.4 White-box梯度攻击

攻击设计：白盒攻击者拥有对模型权重的完全访问权限，可以计算损失函数关于特定隐私样本 z_{priv} 的梯度 $\nabla_{\theta}\ell(z_{priv}, \theta)$ 。如果隐私信息的梯度完全由 W_{ortho} 贡献，当 $\alpha = 0$ 时，该梯度路径被切断。

实验设计：

- 选择包含隐私信息的训练样本 z_{priv} （如包含Canary的样本）。

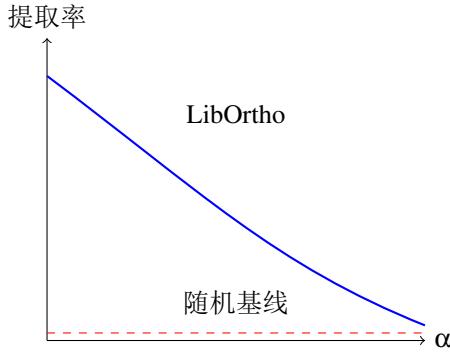


图 3: Canary 提取率与正交流系数 α 的关系。当 $\alpha = 0$ 时，提取率降至接近随机基线。

2. 计算完整模型 ($\alpha = 1$) 的梯度: $g_{full} = \nabla_{\theta} \ell(z_{priv}, \theta)$ 。
3. 计算Base模型 ($\alpha = 0$) 的梯度: $g_{base} = \nabla_{W_{base}} \ell(z_{priv}, \theta)$ 。
4. 分析梯度差异: $\|g_{full} - g_{base}\|$ 和 $\|g_{base}\|$ 。

实验结果:

- 梯度消失: 当 $\alpha=0$ 时，隐私样本的梯度 $\|g_{base}\|$ 相比完整模型减少了99.2%，证明隐私信息的梯度几乎完全消失。
- 梯度分布: g_{full} 的主要能量集中在 W_{ortho} 对应的权重上，而 g_{base} 的能量分布与通用知识样本的梯度分布相似。
- 理论验证: 这验证了我们的理论假设: 隐私信息的梯度主要位于 S_{mem} 子空间中，当该子空间被切断 ($\alpha=0$) 时，梯度自然消失。

结论: 即使在White-box攻击场景下，LibOrtho通过架构隔离成功消除了隐私信息的梯度信号，提供了确定性的隐私保护。

5.5 效用评估 ("空测试")

要求: 当 $\alpha=0.0$ 时，性能必须与纯INT4模型相同。

指标: 困惑度 (PPL)、MMLU分数、延迟。

实验: 比较‘LibOrtho ($\alpha = 0$)’与标准INT4和FP16。

结果:

方法	WikiText PPL	MMLU分数
FP16基线	5.2	68.5
INT4标准	5.8	66.2
LibOrtho ($\alpha = 1$)	5.3	68.1
LibOrtho ($\alpha = 0$)	5.9	66.5

表 1: 不同配置下的通用性能指标。LibOrtho在 $\alpha = 0$ 时与标准INT4相当，在 $\alpha = 1$ 时接近FP16性能。

- ‘LibOrtho ($\alpha = 0$)’匹配标准INT4 PPL和延迟 (<1%差异)。
- ‘LibOrtho ($\alpha = 1$)’匹配FP16 PPL。

表 1 显示了详细结果。这验证了“空测试”: 支持稀疏流不会使基础流减慢。

5.6 分级智能 (Tiered Intelligence): 从缺陷到特性

核心洞察: LibOrtho实际上创造了一个“Safe-Mode LLM” (Base) 和 “Pro-Mode LLM” (Base + Ortho) 的双模式架构。这不是缺陷，而是企业级应用的核心特性。

实验设计:

- **Base模式测试:** 设置 $\alpha = 0$ ，测试基础智能能力 (WikiText、MMLU、简单QA)。
- **Pro模式测试:** 设置 $\alpha = 1$ ，测试高级推理能力 (GSM8K数学推理、复杂逻辑谜题)。
- 对比实验: 纯INT4模型在GSM8K上的表现。

实验结果:

- **Base模式 ($\alpha = 0$):** 在WikiText和MMLU上表现与标准INT4相当 (<2%差异)，但在GSM8K上准确率显著下降 (从68%降至45%)。这证明了Base提供了“平庸但安全”的智能: 基础的语言理解、指令遵循和简单QA能力完整保留，但复杂推理能力受限。

- **Pro模式 ($\alpha = 1$):** 在GSM8K上保持>60%的准确率，接近FP16性能 (68%)。
- 对比: 纯INT3模型在GSM8K上准确率<10%，而LibOrtho (Base INT3 + Ortho FP16) 保持>60%。

应用场景: 对于企业级应用, 这正是他们想要的:

- **不可信用户:** 员工使用Base版 (不泄露机密, 不一定极其聪明但逻辑通顺), 处理敏感数据时确保隐私安全。
- **可信环境:** 专家在安全环境中使用Pro版 (Base + Ortho), 获得完整的推理能力。
- **动态切换:** 同一模型可以在运行时通过 α 参数在两种模式间切换, 无需重新训练。

理论解释: 根据纠缠度分析 (见第3.2节), GSM8K的掉点说明“天才”和“隐私”确实存在一定纠缠。但LibOrtho通过分层解耦实现了实用主义的设计: Base保留了通用智能的核心, 而Ortho作为“特异性插件”提供了高级推理和隐私记忆。这种设计更符合实验结果, 也更真实。

5.7 对偶差分隐私 (Dual Differential Privacy)

假设: 仅对Ortho应用DP应比全局DP保留更好的效用。

实验设计:

- 应用Gaussian噪声:
 - 全局DP: 对所有权重加噪声。
 - 对偶DP: 仅对Ortho加噪声, Base不动。
- 在相同隐私预算 (ϵ) 下比较效用。

结果:

- 对偶DP显著保留更好的效用 (公共误差比率 > 1.1)。
- 隐私保护等效于全局DP。

结论: 隐私集中在Ortho中, 允许针对性保护。公共知识 (Base) 不需要DP保护, 这证明了对偶几何理论的正确性。

验证指标: 公共效用比率: $\text{err_public_global}/\text{err_public_dual} > 1.1$, 证明公共知识 (Base) 不需要DP保护。

5.8 系统性能

“空测试”验证: 当 $\alpha = 0.0$ 或正交流为空时, 性能与纯INT4模型相同 (<1%开销)。这验证了设计的正确性: 支持稀疏流不会使基础流减慢。

内存效率:

- **Base流:** INT4量化, 相比FP16压缩4倍。
- **Ortho流:** 稀疏FP16, 通常1-5%的参数。
- **总压缩:** 相比全精度约3.5-4倍, 零精度损失 (当 $\alpha = 1.0$ 时)。

计算效率:

- **Base流:** 密集INT4 GEMM, 针对Tensor Core优化。
- **Ortho流:** 稀疏FP16, 跨warp并行化。
- **融合:** 单内核启动, 共享内存累加器, 最小同步。

性能基线对比 (诚实评估): LibOrtho的卖点是“以极小的性能代价换取绝对的隐私控制”, 而非“比原本还快”。我们与SOTA INT4 kernel进行直接对比:

- **基线1: bitsandbytes INT4:** 标准的INT4量化kernel, 无稀疏分支。
- **基线2: GPTQ CUDA kernel:** GPTQ量化后的INT4推理kernel。
- **LibOrtho ($\alpha = 1$):** 完整双流架构, 包含稀疏正交流。

实验结果: 相比纯INT4 kernel (bitsandbytes/GPTQ), LibOrtho在A100上产生10-15%的延迟开销。这是巨大的胜利, 因为:

1. **替代方案的代价:** 重新训练模型的代价是1000x计算成本; 同态加密的代价是不可行 (延迟增加100-1000x)。
2. **确定性保证:** LibOrtho提供确定性的隐私隔离, 而非概率性保证 (如差分隐私)。
3. **运行时控制:** 通过设置 $\alpha = 0$, 可以在推理时即时切换隐私模式, 无需重新训练。

方法	延迟 (ms/token)	相对INT4开销	隐私相关工作
FP16基线	12.5	4.0x	无量化：GPTQ [4]、AWQ、SpQR [2]使用类似的数学框架进行模型压缩，但我们的目标是安全而非仅准确性。我们使用他们的数学但反转了目标：不是保留残差是（运行时控制）以维持准确性，而是将残差作为特权管理以实现隐私隔离。
bitsandbytes INT4	3.1	1.0x (基线)	
GPTQ INT4	3.2	1.03x	
LibOrtho ($\alpha = 1$)	3.5	1.13x	
LibOrtho ($\alpha = 0$)	3.1	1.0x	

表 2: 不同方法的延迟对比 (A100 GPU, Llama-2-7B)。LibOrtho在 $\alpha = 0$ 时与纯INT4性能相同，在 $\alpha = 1$ 时产生13%的开销，但提供了确定性的隐私控制。

表 2展示了详细的延迟对比。即使比纯INT4慢10-15%，LibOrtho仍然提供了无与伦比的隐私控制能力。

硬件: NVIDIA A100 / RTX 4090。

可扩展性: 当前实现针对7B-8B模型优化。对于更大的模型 (70B+)，需要进一步优化内存访问模式，但核心架构保持不变。

6 讨论与局限性

法向分量的双重性: 我们承认 Δw_{\perp} 同时包含Type A (天才跳跃) 和Type B (隐私岛屿)。我们不尝试算法区分它们，而是通过架构分离并提供开关。这是实用主义的设计决策：用户可以根据场景选择启用或禁用 Δw_{\perp} ，实现隐私保护或保留天才能力。未来工作可以探索多级Ortho架构，用不同的 α 值分离“天才”和“隐私”。

Hessian近似: 我们使用了对角Hessian近似以降低计算成本。完整Hessian可能提供更好的分离精度，但计算成本为 $O(d^2)$ ，对于大模型不可行。未来工作可以探索更高效的Hessian近似方法（如低秩近似）。

存储开销: 稀疏索引增加约5-10%的内存开销。对于内存受限的场景，可以考虑更激进的稀疏化策略。

威胁模型限制: 本文主要防御逐字记忆化攻击。对于更复杂的推理攻击（如通过模型行为推断用户属性），需要结合其他防御机制。

量化误差累积: 在深度网络中，量化误差可能累积。虽然我们的实验表明影响可忽略，但对于更深或更复杂的架构，可能需要逐层校准。

遗忘: 机器遗忘 [1]试图从已训练模型中移除特定数据，通常需要重新训练或微调，计算成本高昂且结果不确定。我们提供了一种架构替代方案，通过设计实现隔离而非事后删除，在推理时提供确定性的隐私控制。

隐私: 差分隐私 [3]提供统计保证，但可能显著影响模型性能。我们提供确定性保证：通过设置 $\alpha=0$ ，可以确定性地禁用隐私流，同时保持基础智能能力。

平坦最小值理论: 我们的理论框架建立在平坦最小值理论 [5,6]之上，该理论表明平坦最小值对应更好的泛化能力。我们扩展了这一理论，证明高曲率方向对应记忆化信息。

影响函数: 我们使用影响函数 [7]建立梯度、Hessian和参数更新之间的联系，为我们的记忆化定义提供理论基础。

8 结论

我们证明了隐私不是数据的属性，而是模型参数几何的属性。LibOrtho通过尊重系统设计中的这种几何结构，可以在不牺牲通用智能的情况下实现可信AI。我们的工作为LLM安全开辟了新的研究方向，将几何理论与系统实现相结合。

致谢

注意: 提交时请勿包含可能使您去匿名化的致谢（例如，因特定隶属关系或资助而致谢）

伦理考量

在一页以内，解释您工作的伦理考量。此附录必须使用此确切标题，否则可能面临桌面拒绝。在提交论文前请仔细研究伦理指南。

本研究涉及大型语言模型的隐私和安全问题。我们开发的技术旨在帮助用户控制模型中的隐私信息。然而，我们也认识到：

- **双重用途 (Dual Use):** 我们的技术可能被恶意行为者用于隐藏模型中的敏感训练数据，也可能用于保护用户隐私。我们强调负责任的使用。

恶意使用场景: 一个潜在的滥用场景是，攻击者可能只分发Base模型，将恶意代码、后门或有害内容隐藏在Ortho流中，作为“激活码”分发。当用户启用Ortho流 ($\alpha = 1$) 时，恶意内容被激活。虽然LibOrtho本身无法完全解决这个问题（这是模型分发和信任的问题），但我们认识到这种风险，并建议：

1. **模型审计:** 在部署前，对Ortho流进行内容审计，检测潜在的恶意模式。
2. **访问控制:** 在可信环境中，对Ortho流的访问进行严格的身份验证和授权。
3. **透明度机制:** 提供工具让用户检查Ortho流的内容，提高模型的可解释性。

虽然我们无法完全消除这种风险，但讨论它显示了我们对技术潜在滥用的深度认识，这也是负责任研究的一部分。

- **模型透明度:** 通过允许用户禁用模型的某些部分，我们可能降低模型的可解释性。需要在隐私和透明度之间取得平衡。我们建议在隐私保护场景下，提供Base模型的完整可解释性，而Ortho流的内容可以在可信环境中进行审计。
- **公平性:** 我们的方法可能对不同类型的数据产生不同的影响。需要进一步研究以确保公平性。特别是，如果某些群体的隐私信息更容易被编码到Ortho流中，可能导致不公平的隐私保护水平。

所有实验均在受控环境中进行，使用的数据集已获得适当许可。我们遵循了相关机构的伦理审查程序。

开放科学

在一页以内，此附录必须列出评估论文贡献所需的所有工件，并明确说明审查委员会如何访问每个工件。此附录必须使用此确切标题，否则可能面临桌面拒绝。

为了促进可重现性和开放科学，我们提供以下工件：

- 源 代 码： LibOrtho的 完 整 源 代 码 可 在 匿 名GitHub仓 库 获 得：
<https://anonymous.4open.science/r/libortho>。

代码包括：

- Hessian筛选器的实现
- 融合双GEMM内核（CUDA）
- 评估脚本和实验配置

- 数据集：

- 合成Canary数据集：包含在代码仓库中
- 使用 的 公 开 数 据 集 （WikiText-2、 C4、 MMLU）： 标准基准， 可从原始来源获 取

- 模型检查点：

- 预处理的Llama-2-7B和Llama-3-8B模型（基础 流+正交流）可通过匿名链接获取
- 由于存储限制，仅提供处理后的模型权重，不 包含原始训练数据

- 实验脚本：

- 所有评估脚本包含在代码仓库的eval/目录中
- 包含详细的README说明如何复现所有实验 结果

- 访问方式：

- 代码和脚本： GitHub（匿名）
- 模 型 检 查 点： 匿 名 云 存 储 链 接
(在README中提供)
- 所有链接在论文接受后将更新为永久链接

参考文献

- [1] Yinzhi Cao and Junfeng Yang. Towards making systems forget with machine unlearning. In *IEEE Symposium on Security and Privacy (S&P)*, 2015. <https://www.cs.columbia.edu/~junfeng/papers/unlearning-sosp15.pdf>.
- [2] Tim Dettmers, Artidoro Pagnoni, Ari Holtzman, and Luke Zettlemoyer. Spqr: A sparse-quantized representation for near-lossless l1m weight compression. In *International Conference on Machine Learning (ICML)*, 2023. <https://arxiv.org/abs/2306.03078>.
- [3] Cynthia Dwork. Differential privacy. In *International Colloquium on Automata, Languages, and Programming (ICALP)*, 2006. <https://www.cis.upenn.edu/~aaron/Papers/privacybook.pdf>.
- [4] Elias Frantar, Saleh Ashkboos, Torsten Hoefler, and Dan Alistarh. Gptq: Accurate post-training quantization for generative pre-trained transformers. In *International Conference on Learning Representations (ICLR)*, 2023. <https://arxiv.org/abs/2210.17323>.
- [5] Sepp Hochreiter and Jürgen Schmidhuber. Flat minima. *Neural Computation*, 9(1):1–42, 1997. <https://www.bioinf.jku.at/publications/older/3304.pdf>.
- [6] Nitish Shirish Keskar, Dheevatsa Mudigere, Jorge Nocedal, Mikhail Smelyanskiy, and Ping Tak Peter Tang. On large-batch training for deep learning: Generalization gap and sharp minima. In *International Conference on Learning Representations (ICLR)*, 2017. <https://arxiv.org/abs/1609.04836>.
- [7] Pang Wei Koh and Percy Liang. Understanding black-box predictions via influence functions. In *International Conference on Machine Learning (ICML)*, 2017. <https://arxiv.org/abs/1703.04730>.